**Московский государственный технический университет им. Н.Э. Баумана**

Факультет «Информатика и системы управления»
Кафедра ИУ5 «Системы обработки информации и управления»

Курс

«Технологии машинного обучения»

Отчет по лабораторной работе №1

# «Разведочный анализ данных. Исследование и визуализация данных.»

Выполнил:
студент группы ИУ5-63Б
Воронова О. А.

Проверил:
преподаватель каф. ИУ5
Гапанюк Ю.Е.

Москва, 2022 г.

# Разведочный анализ данных

## Задание:

- Выбрать набор данных (датасет). Вы можете найти список свободно распространяемых датасетов здесь.
- Для первой лабораторной работы рекомендуется использовать датасет без пропусков в данных, например из Scikit-learn.
- Пример преобразования датасетов Scikit-learn в Pandas Dataframe можно посмотреть здесь. Для лабораторных работ не рекомендуется выбирать датасеты большого размера.
- Создать ноутбук, который содержит следующие разделы:

1. Текстовое описание выбранного Вами набора данных.
2. Основные характеристики датасета.
3. Визуальное исследование датасета.
4. Информация о корреляции признаков.

- Сформировать отчет и разместить его в своем репозитории на github.

## 1) Текстовое описание набора данных

В качестве набора данных будем использовать датасет в котором содержится информация о ценах пиццы в различных популярных пиццериях. Файл pizza_data.csv содержит следующие колонки:

- Company - Название компании
- Pizza Name - Название пиццы
- Type - Тип пиццы
- Size - Размер пиццы в дюймах
- Price - Цена пиццы в долларах

Импорт библиотек

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
```

Загрузка данных

```
df = pd.read_csv("pizza_data.csv")
```

## 2) Основные характеристики датасета

```
#Отобразим первые 5 строк датасета:
df.head()
```

| | Company | Pizza Name | Type | Size | Price |
|---|---|---|---|---|---|
| 0 | Domino's Pizza | Hand Tossed | Cheeses Pizza | Small (10") | $5.99 |
| 1 | Domino's Pizza | Hand Tossed | Cheeses Pizza | Medium (12") | $7.99 |
| 2 | Domino's Pizza | Hand Tossed | Cheeses Pizza | Large (14") | $9.99 |
| 3 | Domino's Pizza | Handmade Pan | Cheeses Pizza | Medium (12") | $7.99 |
| 4 | Domino's Pizza | Crunchy Thin Crust | Cheeses Pizza | Small (10") | $5.99 |

```
#Определим размер датасета
size = df.shape
print("Всего строк: {}".format(size[0]))
print("Всего столбцов: {}".format(size[1]))
Всего строк: 371
Всего столбцов: 5
#Список колонок с типами данных
df.dtypes
Company       object
Pizza Name    object
Type          object
Size          object
Price         object
dtype: object
```

Преобразуем столбцы "Price" и "Size" в тип float и int соответственно:

```
for i in range(df.shape[0]):
    df["Price"][i] = float(df["Price"][i][1:])
    if "Small" in df["Size"][i]:
        df["Size"][i] = 10
    elif "Medium" in df["Size"][i]:
        df["Size"][i] = 12
    elif "Large" in df["Size"][i]:
        df["Size"][i] = 14
    elif "X-Large" in df["Size"][i]:
        df["Size"][i] = 16
    elif "Personal" in df["Size"][i]:
        df["Size"][i] = 7
    elif "Mini" in df["Size"][i]:
        df["Size"][i] = 8
    elif "Jumbo" in df["Size"][i]:
        df["Size"][i] = 18
df["Size"] = df["Size"].astype("int")
df["Price"] = df["Price"].astype("float")
#Проверим результат
```

```
df.dtypes
Company         object
Pizza Name      object
Type            object
Size             int32
Price          float64
dtype: object
#Проверка на наличие пустых значений
for col in df.columns:
    temp = df[df[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp))
Company - 0
Pizza Name - 0
Type - 0
Size - 0
Price - 0
#Найдём основные статичтические характеристики набора данных
df.describe()
```

| | Size | Price |
|---|---|---|
| count | 371.000000 | 371.000000 |
| mean | 12.506739 | 16.319326 |
| std | 2.290246 | 5.714662 |
| min | 7.000000 | 4.290000 |
| 25% | 12.000000 | 12.490000 |
| 50% | 12.000000 | 15.490000 |
| 75% | 14.000000 | 19.950000 |
| max | 18.000000 | 29.990000 |

## 3) Визуальное исследование датасета

Диаграмма расеяния

```
fig, ax = plt.subplots(figsize=(8,8))
sns.scatterplot(ax=ax, x='Size', y='Price', data=df)
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

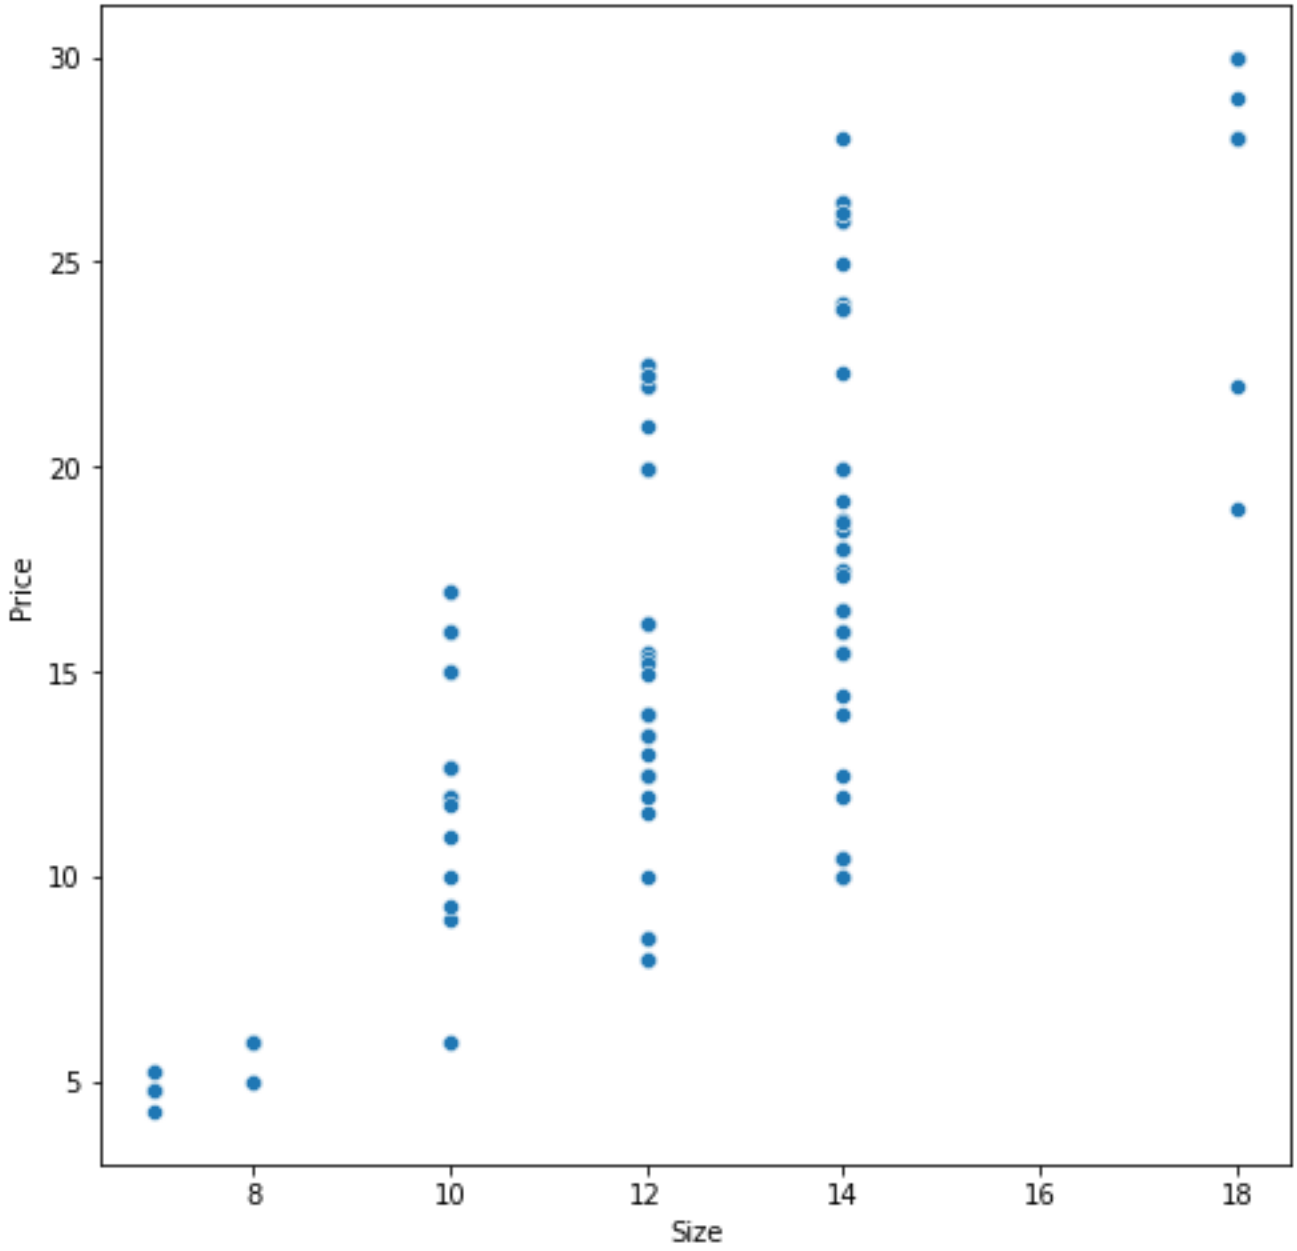


```
#Зависимость цены и размера от типа пиццы
fig, ax = plt.subplots(figsize=(8,8))
sns.scatterplot(ax=ax, x='Size', y='Price', data=df,
hue="Type")
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

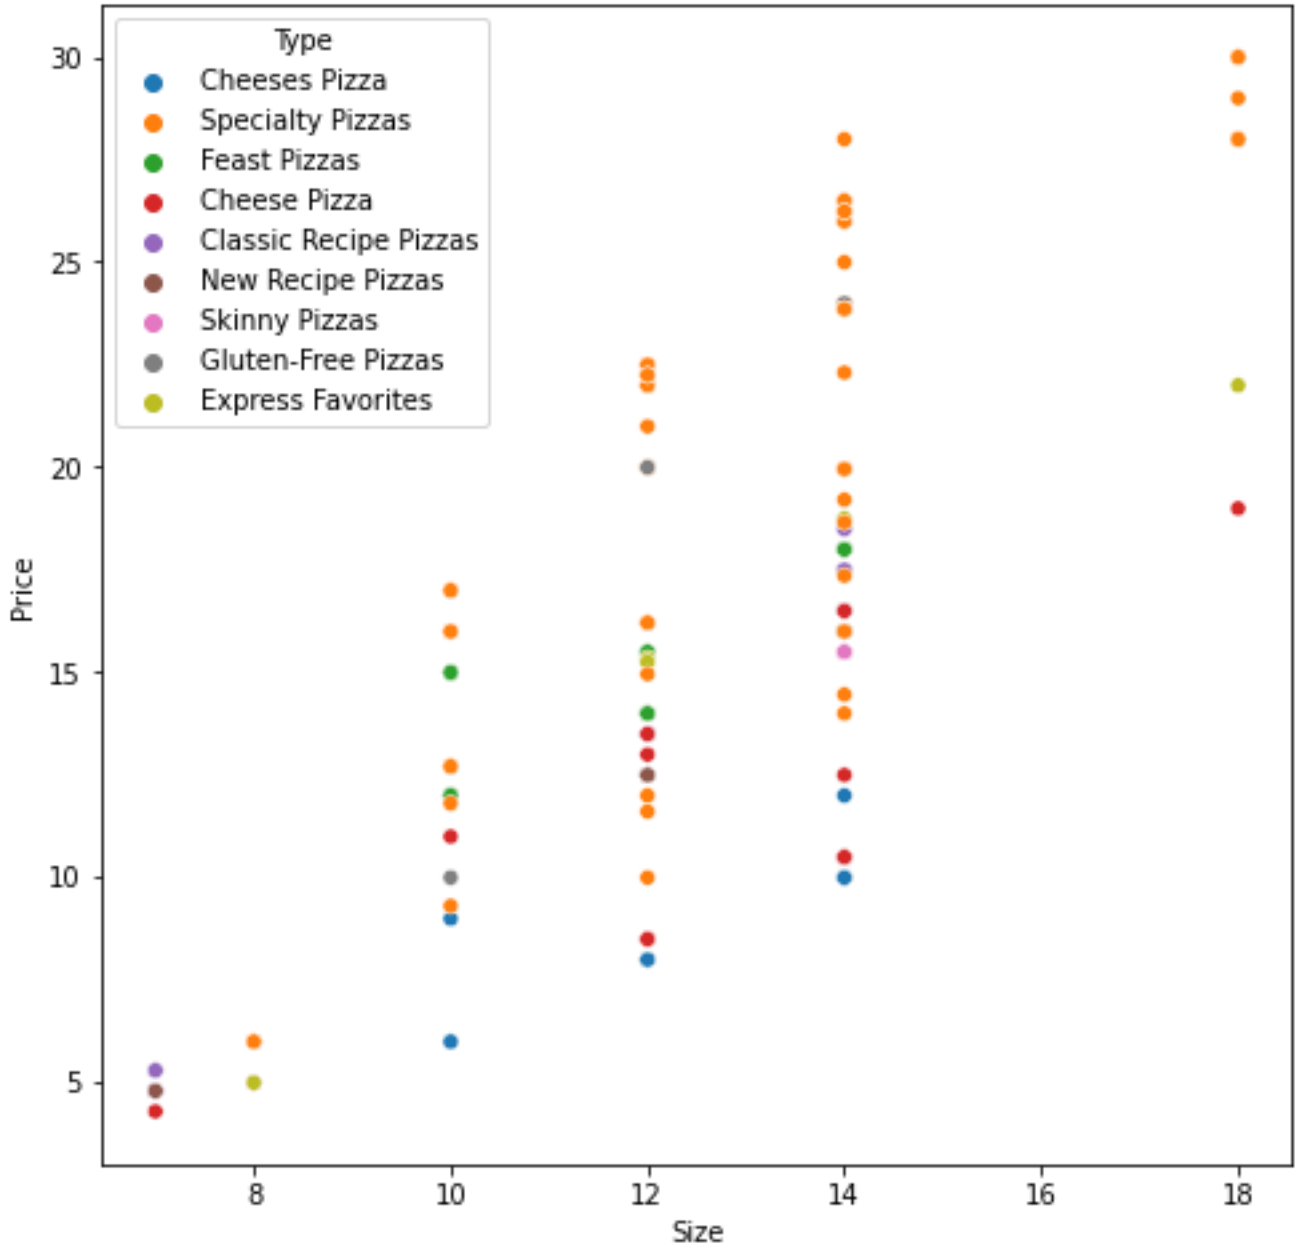


Гистограмма

```
#Оценим распределение цены с помощью гистограммы
fig, ax = plt.subplots(figsize=(8,8))
sns.distplot(df["Price"])
D:\Anaconda\lib\site-packages\seaborn\distributions.py:2619:
FutureWarning: `distplot` is a deprecated function and will be
removed in a future version. Please adapt your code to use
either `displot` (a figure-level function with similar
flexibility) or `histplot` (an axes-level function for
histograms).
  warnings.warn(msg, FutureWarning)
<AxesSubplot:xlabel='Price', ylabel='Density'>
```

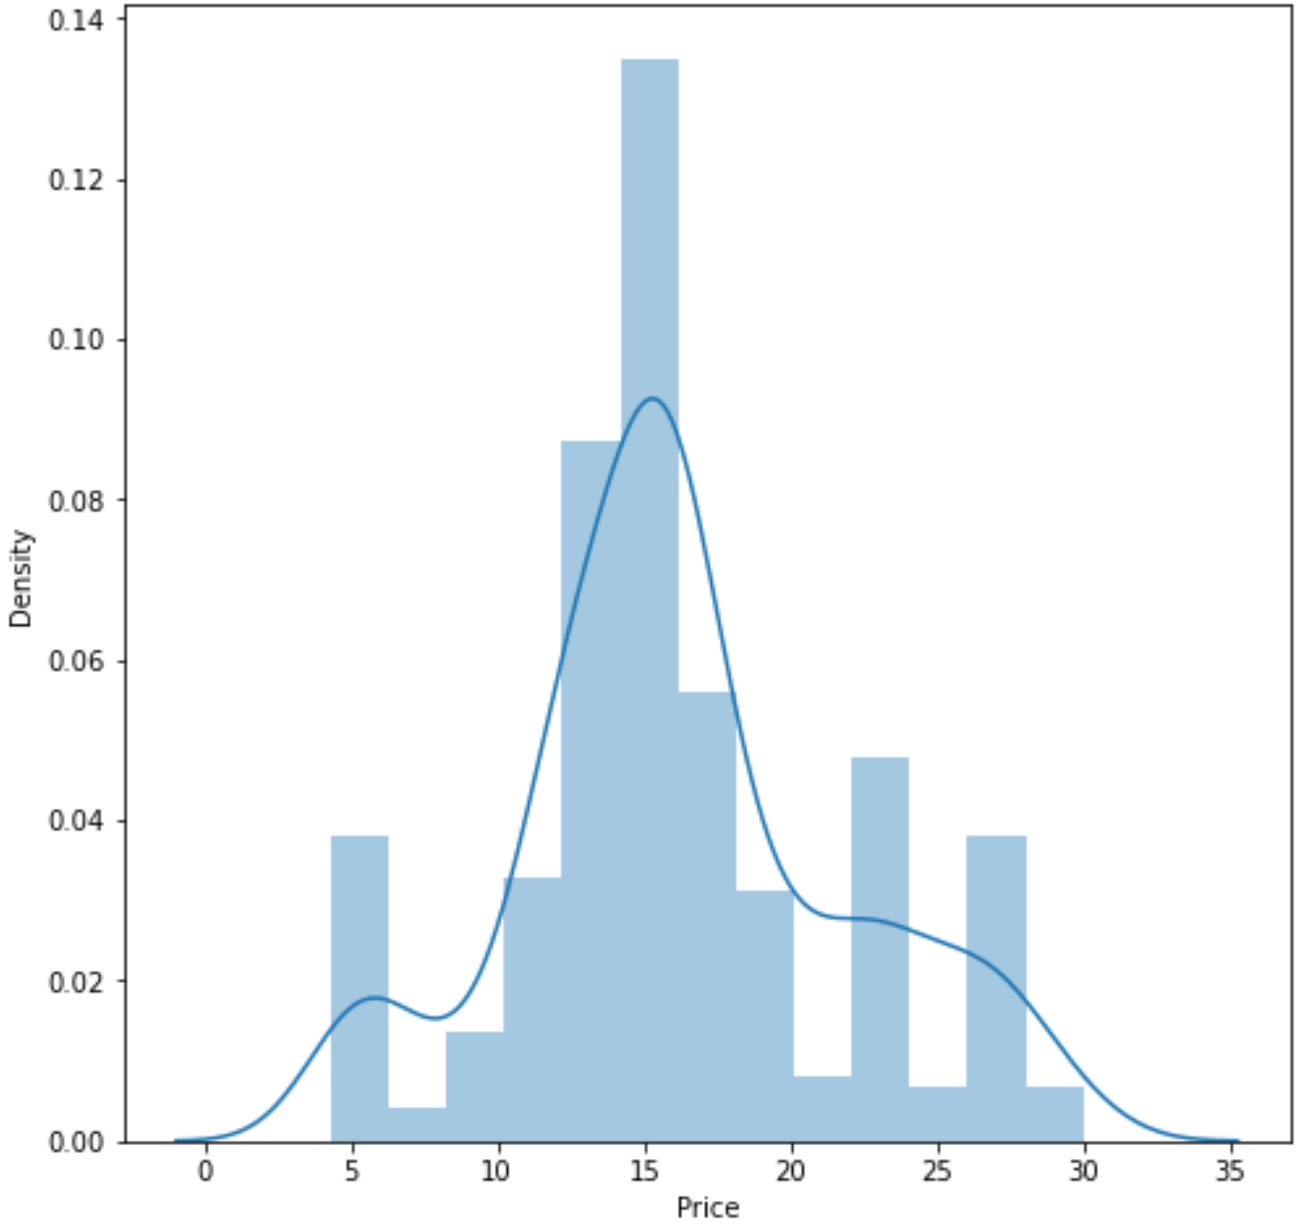


```
#Комбинация гистограмм и диаграмм рассеивания
sns.jointplot(x='Size', y='Price', data=df)
<seaborn.axisgrid.JointGrid at 0x233beed46a0>
```

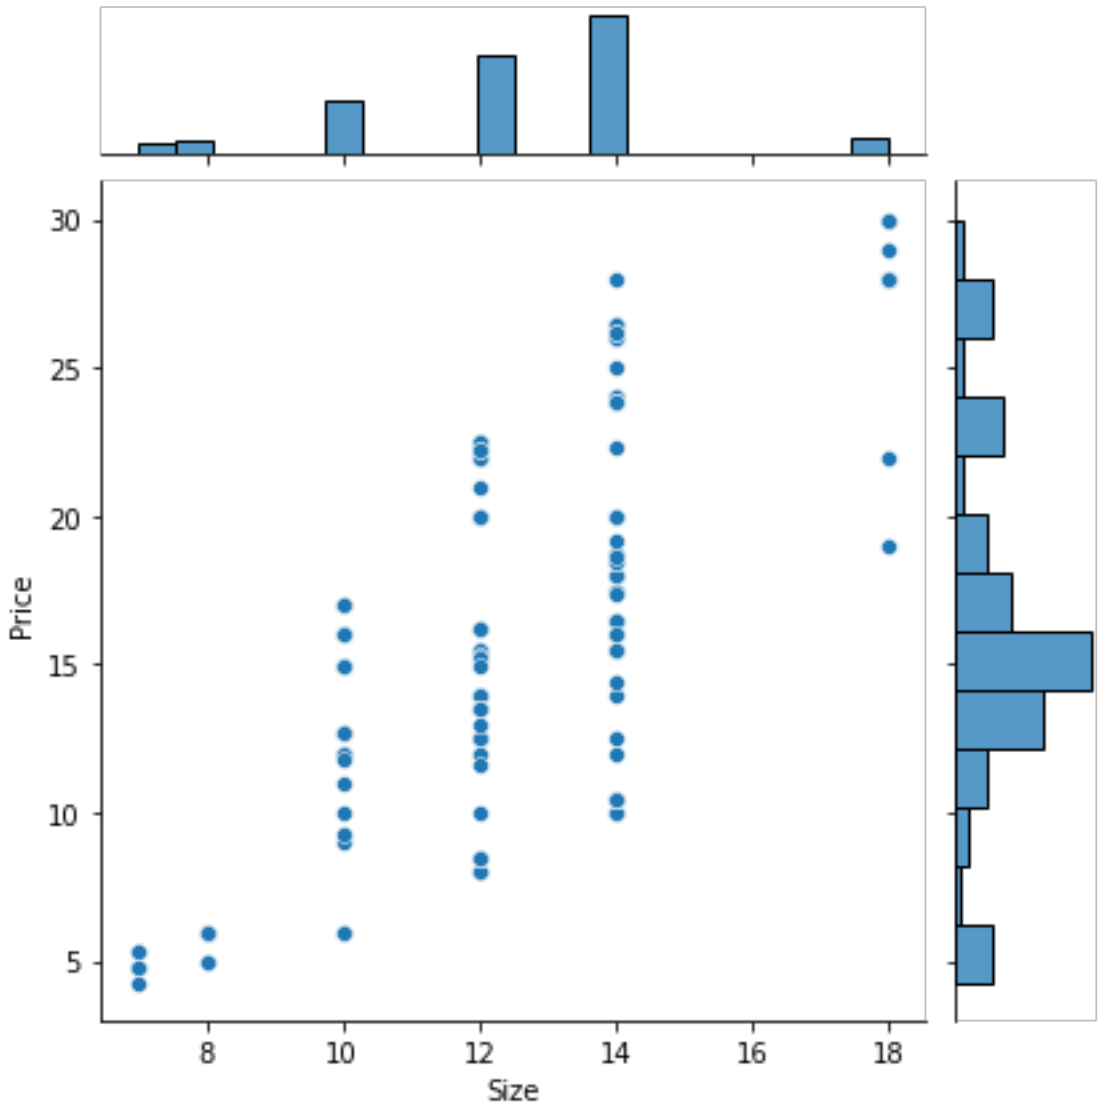


```
sns.jointplot(x='Size', y='Price', data=df, kind="hex")
<seaborn.axisgrid.JointGrid at 0x233bf060820>
```

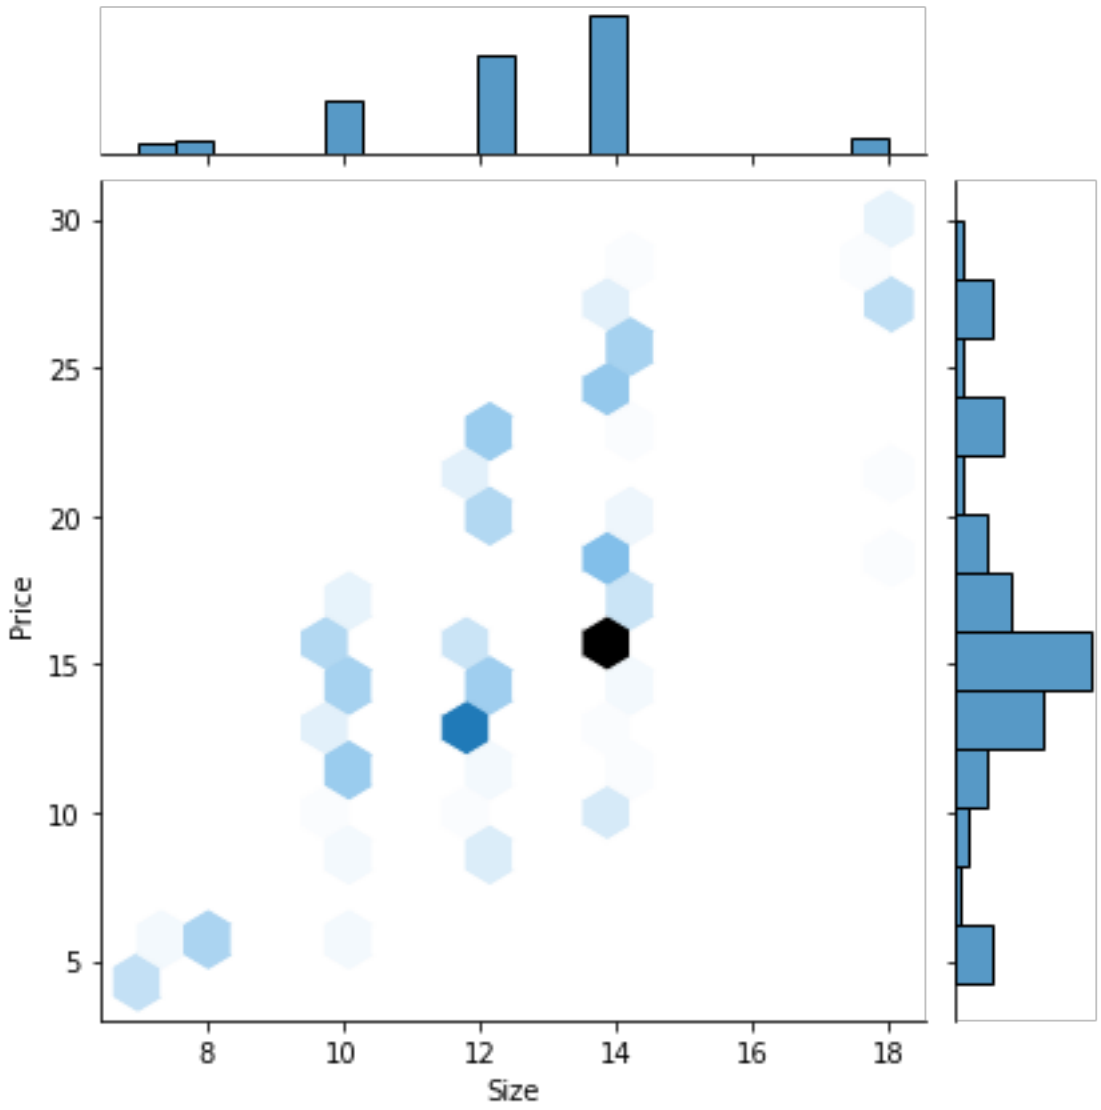


```
#Парные диаграммы
sns.pairplot(df)
<seaborn.axisgrid.PairGrid at 0x233bf1eeee0>
```

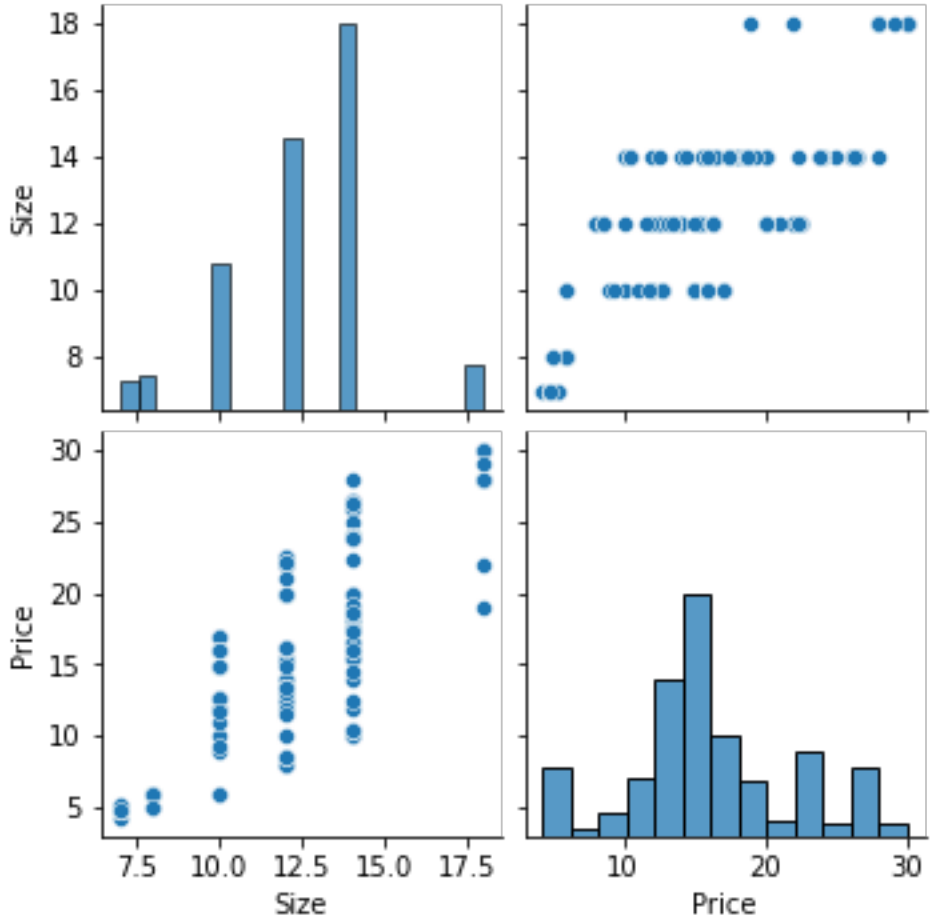


Ящик с усами

```
sns.boxplot(x=df["Price"])
<AxesSubplot:xlabel='Price'>
```

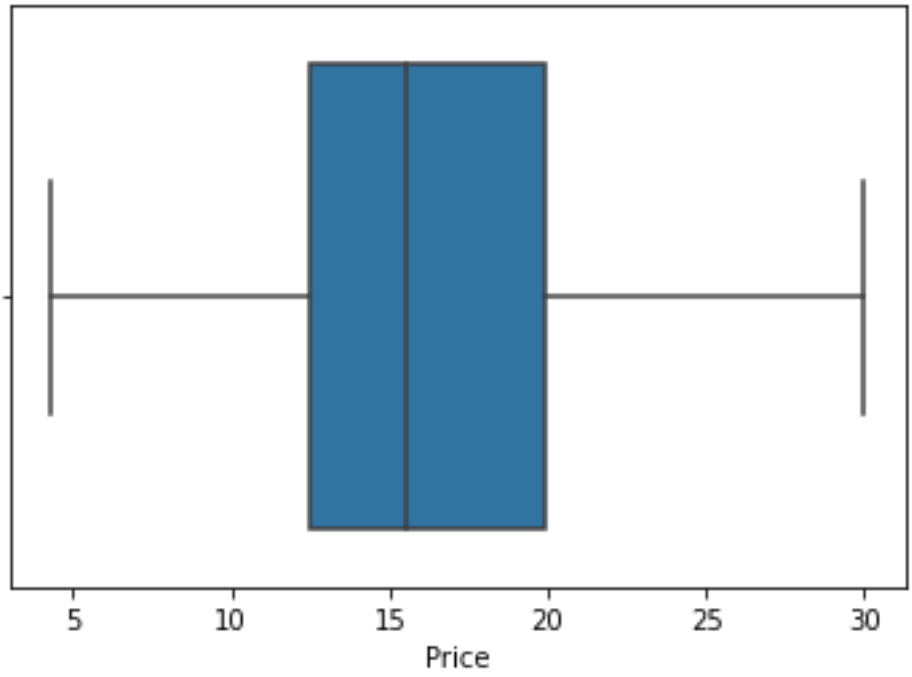


```
sns.boxplot(x="Price", y="Company", data=df)
<AxesSubplot:xlabel='Price', ylabel='Company'>
```

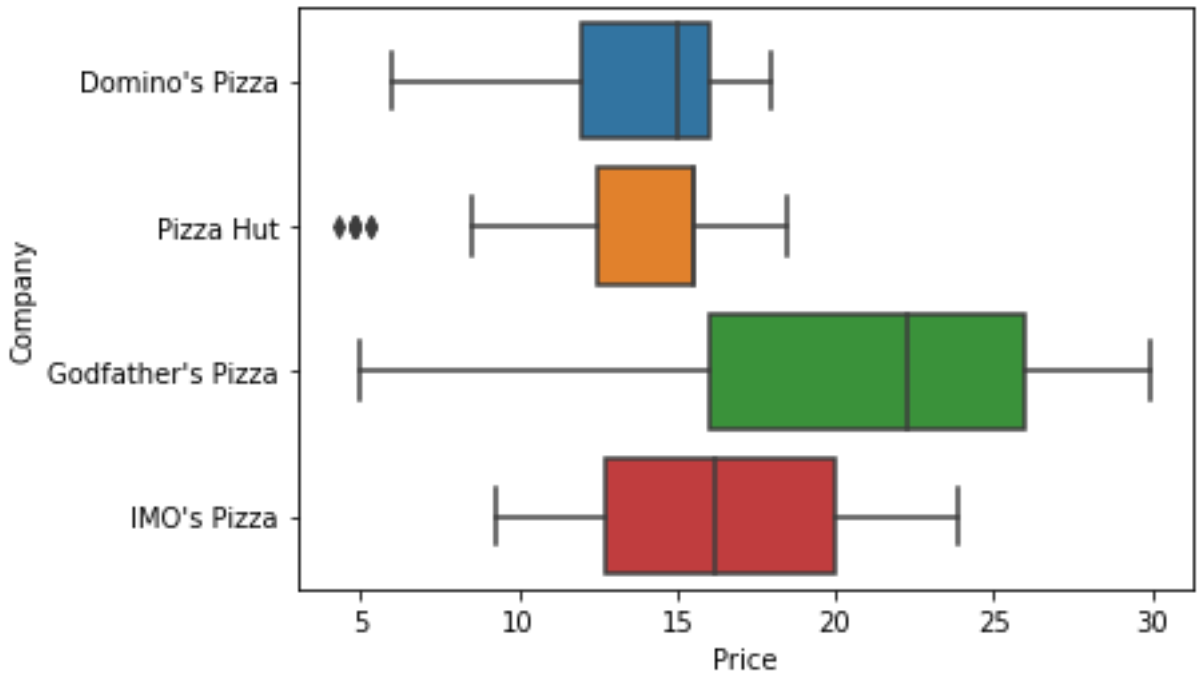


Violin plot

```
sns.violinplot(x=df["Size"])
<AxesSubplot:xlabel='Size'>
```

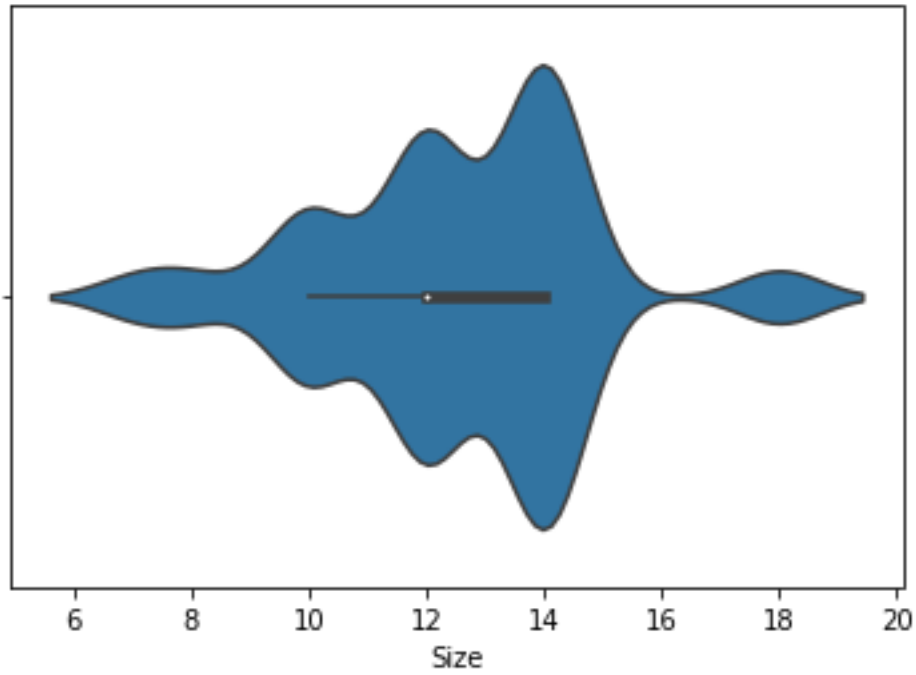


```
sns.violinplot(x="Size", y="Price", data=df)
<AxesSubplot:xlabel='Size', ylabel='Price'>
```

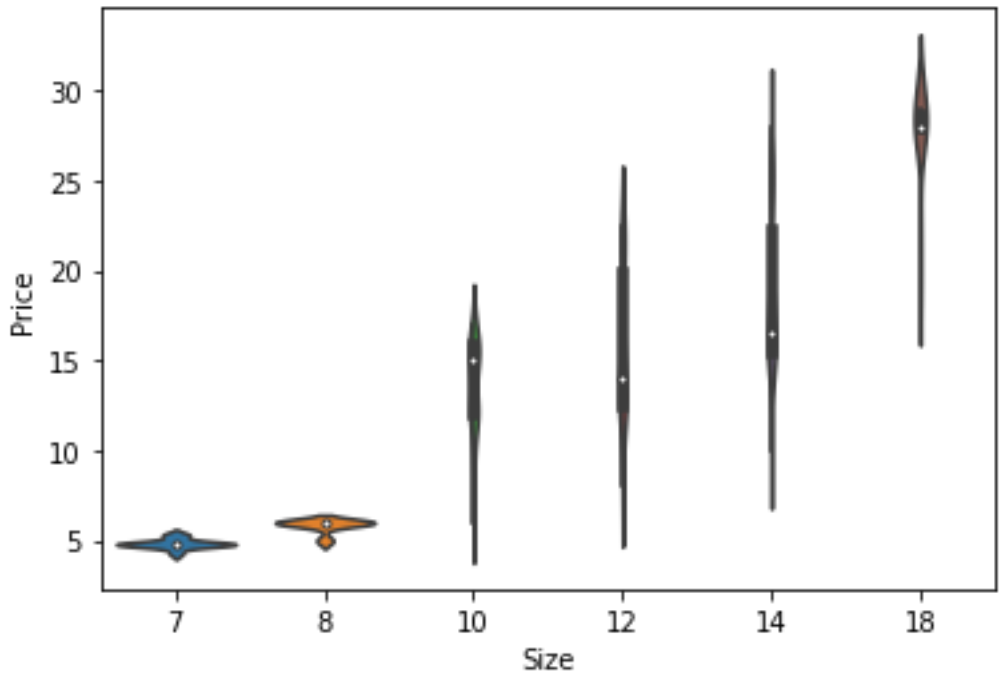


## 4) Информация о корреляции признаков

```
#Корреляция по критерию Пирсона
df.corr(method="pearson")
```

| | Size | Price |
|---|---|---|
| **Size** | 1.000000 | 0.711833 |
| **Price** | 0.711833 | 1.000000 |

```
#Корреляция Кендалла
df.corr(method="kendall")
```

| | Size | Price |
|---|---|---|
| **Size** | 1.000000 | 0.525855 |
| **Price** | 0.525855 | 1.000000 |

```
#Корреляция Спирмена
df.corr(method="spearman")
```

| | Size | Price |
|---|---|---|
| **Size** | 1.000000 | 0.633828 |
| **Price** | 0.633828 | 1.000000 |

```
#Визуализация корреляционной матрицы
sns.heatmap(df.corr(), annot=True, fmt=".4f", cmap="YlGnBu")
```

<AxesSubplot:>

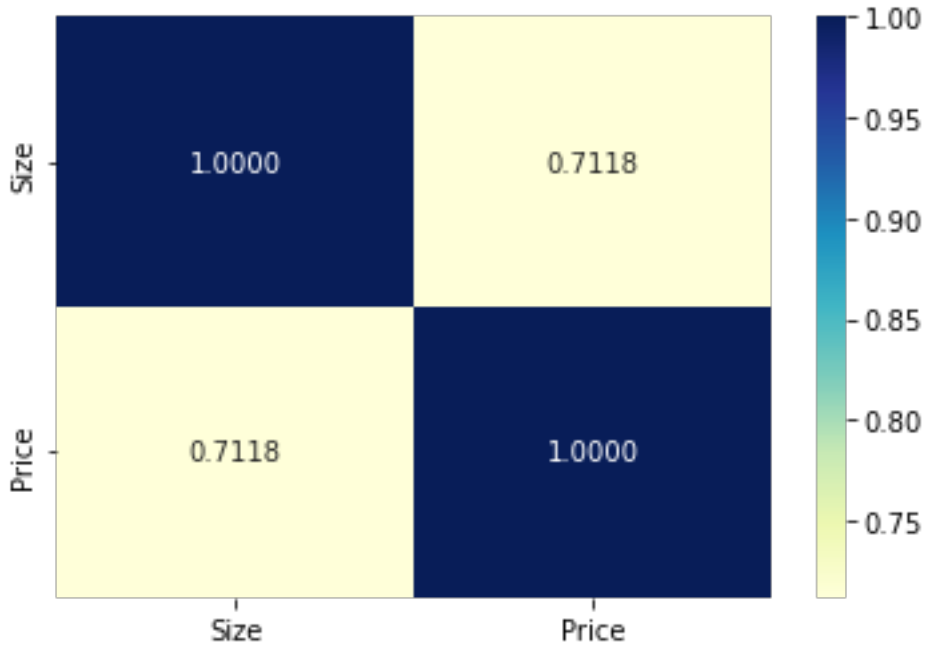


```
fig, ax = plt.subplots(1, 3, sharex="col", sharey="row",
figsize=(15,5))
sns.heatmap(df.corr(method="pearson"), ax=ax[0], annot=True,
fmt=".4f")
sns.heatmap(df.corr(method="kendall"), ax=ax[1], annot=True,
fmt=".4f")
sns.heatmap(df.corr(method="spearman"), ax=ax[2], annot=True,
fmt=".4f")
fig.suptitle("Корреляционные матрицы, построенные различными
методами")
ax[0].title.set_text("Пирсон")
ax[1].title.set_text("Кендалл")
ax[2].title.set_text("Спирмен")
```