Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления»
Кафедра ИУ5 «Системы обработки информации и управления»

Курс

«Технологии машинного обучения»

Отчет по лабораторной работе №5

«Разведочный анализ данных. Исследование и визуализация данных.»

Выполнил:
студент группы ИУ5-63Б
Воронова О. А.

Проверил:
преподаватель каф. ИУ5
Гапанюк Ю.Е.

Москва, 2022 г.

Лабораторная работа №5

Ансамбли моделей машинного обучения

Задание:

1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4. Обучите следующие ансамблевые модели:
   - одну из моделей группы бэггинга (бэггинг или случайный лес или сверхслучайные деревья);
   - одну из моделей группы бустинга;
   - одну из моделей группы стекинга.
5. (+1 балл на экзамене) Дополнительно к указанным моделям обучите еще две модели:
   - Модель многослойного персептрона. По желанию, вместо библиотеки scikit-learn возможно использование библиотек TensorFlow, PyTorch или других аналогичных библиотек.
   - Модель МГУА с использованием библиотеки - https://github.com/kvoyager/GmdhPy (или аналогичных библиотек). Найдите такие параметры запуска модели, при которых она будет по крайней мере не хуже, чем одна из предыдущих ансамблевых моделей.
6. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from typing import Tuple
from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
from sklearn.metrics import balanced_accuracy_score
from sklearn.tree import DecisionTreeClassifier
import graphviz
from sklearn.tree import export_graphviz
from sklearn import tree
from operator import itemgetter
from sklearn.ensemble import RandomForestClassifier,
StackingClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
data = pd.read_csv("Fuel.csv")
#Первые 5 записей датасета
data.head()
```

	Model Year	Make	Model	Vehicle Class	Engine Size(L)	Cylinders	Transmission	Fuel Type	Fue Consumptio (Cit (L/100 km
0	2022	Acura	ILX	Compact	2.4	4	AM8	Z	9.9
1	2022	Acura	MDX SH-AWD	SUV: Small	3.5	6	AS10	Z	12.6
2	2022	Acura	RDX SH-AWD	SUV: Small	2.0	4	AS10	Z	11.0
3	2022	Acura	RDX SH-AWD A-SPEC	SUV: Small	2.0	4	AS10	Z	11.3
4	2022	Acura	TLX SH-AWD	Compact	2.0	4	AS10	Z	11.2

```
#Проверка наличия пустых значений
data.isnull().sum()
Model Year                                0
Make                                      0
Model                                     0
Vehicle Class                             0
Engine Size(L)                            0
Cylinders                                 0
Transmission                              0
Fuel Type                                 0
Fuel Consumption (City (L/100 km)         0
Fuel Consumption(Hwy (L/100 km))          0
Fuel Consumption(Comb (L/100 km))         0
Fuel Consumption(Comb (mpg))              0
CO2 Emissions(g/km)                       0
CO2 Rating                                0
Smog Rating                               0
dtype: int64
#Размер исходного датасета
data.shape
(946, 15)
#Проверка типов
data.dtypes
Model Year                                int64
Make                                     object
```

```
Model                                    object
Vehicle Class                            object
Engine Size(L)                          float64
Cylinders                                 int64
Transmission                             object
Fuel Type                                object
Fuel Consumption (City (L/100 km)       float64
Fuel Consumption(Hwy (L/100 km))        float64
Fuel Consumption(Comb (L/100 km))       float64
Fuel Consumption(Comb (mpg))              int64
CO2 Emissions(g/km)                       int64
CO2 Rating                                int64
Smog Rating                               int64
dtype: object
```

```
#Удаление ненужных столбцов
data = data.drop(columns=["Model", "Model Year"], axis=1)
#Кодирование категориальных признаков
LE = LabelEncoder()
for column in ["Fuel Type","Make", "Vehicle Class",
"Transmission"]:
    data[column] = LE.fit_transform(data[column])
fig, ax = plt.subplots(figsize=(15,9))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True,
fmt='.2f')
<AxesSubplot:>
```

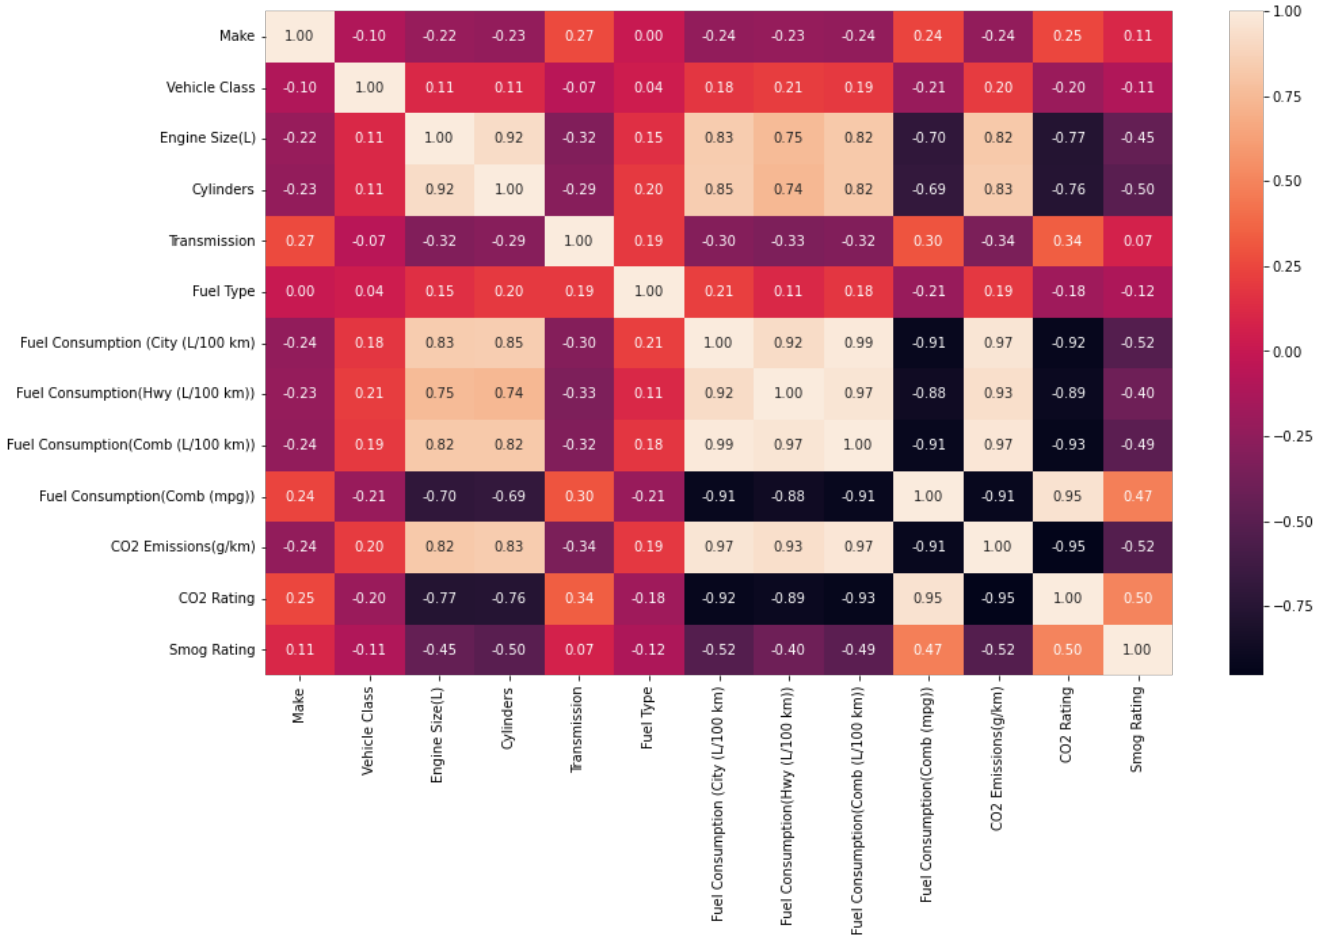

```
#Выделяем записи, где присутствуют 4 или 6 цилиндров
#Для бинарной классификации
data = data.loc[data["Cylinders"].isin([4,6])]
data.shape
(699, 13)
xArray = data.drop("Cylinders", axis=1)
yArray = data["Cylinders"]
#Разделяем выборку для обучения модели
trainX, testX, trainY, testY = train_test_split(xArray, yArray,
test_size=0.2, random_state=1)
```

Случайный лес

```
from sklearn.ensemble import RandomForestClassifier
RForest = RandomForestClassifier(n_estimators=5,
oob_score=True, random_state=10)
RForest.fit(trainX, trainY)
D:\Anaconda\lib\site-packages\sklearn\ensemble\_forest.py:541:
UserWarning: Some inputs do not have OOB scores. This probably
means too few trees were used to compute any reliable oob
estimates.
  warn("Some inputs do not have OOB scores. "
D:\Anaconda\lib\site-packages\sklearn\ensemble\_forest.py:545:
RuntimeWarning: invalid value encountered in true_divide
  decision = (predictions[k] /
RandomForestClassifier(n_estimators=5, oob_score=True,
random_state=10)
estimateRF = balanced_accuracy_score(testY,
RForest.predict(testX))
estimateRF
0.9765625
nums = range(100,1000,100)
RForestarr = list()
for i in range(100,1000,100):
    RForest = RandomForestClassifier(n_estimators=i,
oob_score=True, random_state=10)
    RForest.fit(trainX, trainY)
    RForestarr.append(balanced_accuracy_score(testY,
RForest.predict(testX)))
RForestarr
[0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625,
 0.9765625]
```

Boosting

```
GB = GradientBoostingClassifier(random_state=1)
GB.fit(trainX, trainY)
GradientBoostingClassifier(random_state=1)
balanced_accuracy_score(testY, GB.predict(testX))
0.9765625
```

Stacking

```
base_learners = [
                 ('RF', RandomForestClassifier(n_estimators=10,
random_state=1)),
                 ('GB',
GradientBoostingClassifier(n_estimators=10, random_state=1))
                ]

SC = StackingClassifier(estimators=base_learners,
final_estimator=LogisticRegression())
SC.fit(trainX, trainY)
StackingClassifier(estimators=[('RF',

RandomForestClassifier(n_estimators=10,

random_state=1)),
                               ('GB',

GradientBoostingClassifier(n_estimators=10,

random_state=1))],
                   final_estimator=LogisticRegression())
balanced_accuracy_score(testY, SC.predict(testX))
0.9765625
```